

Prediksi Performa Mahasiswa CSE Menggunakan Algoritma Random Forest

KELOMPOK 6

- Arfal Malik Gibran
- Nabhilla Ayu Larasati

Latar Belakang

Performa akademik mahasiswa merupakan indikator penting dalam menilai keberhasilan proses pembelajaran di perguruan tinggi. Namun, performa akademik tidak hanya dipengaruhi oleh faktor akademik semata, melainkan juga oleh faktor non-akademik seperti kondisi sosial, psikologis, dan pola hidup mahasiswa.

Seiring berkembangnya teknologi informasi dan meningkatnya ketersediaan data pendidikan, pendekatan Educational Data Mining dan Machine Learning mulai banyak dimanfaatkan untuk memprediksi performa mahasiswa secara lebih objektif dan proaktif.



Permasalahan Penelitian

Prediksi performa akademik mahasiswa bukanlah hal yang sederhana karena dipengaruhi oleh banyak faktor yang saling berkaitan. Selama ini, evaluasi performa mahasiswa masih bersifat reaktif dan dilakukan setelah terjadi penurunan prestasi.

- Permasalahan utama yang diangkat dalam penelitian ini adalah:
- Kompleksitas faktor yang memengaruhi performa akademik
- Minimnya pemanfaatan faktor non-akademik
- Kebutuhan akan model prediksi berbasis data yang stabil dan akurat



Tujuan Penelitian



Tujuan dari penelitian ini adalah:

- Membangun model prediksi performa akademik mahasiswa menggunakan algoritma Random Forest
 - Membandingkan performa Random Forest dengan model baseline Logistic Regression
 - Mengidentifikasi faktor-faktor dominan yang memengaruhi performa akademik mahasiswa
 - Memberikan dasar bagi institusi pendidikan untuk perencanaan intervensi dini
-

Dataset dan Sumber Data

Dataset yang digunakan adalah CSE Student Dataset yang diperoleh dari platform Kaggle.

Karakteristik dataset:

- Jumlah data: 99 mahasiswa
- Jenis data: numerik dan kategorikal
- Atribut mencakup data demografis, kebiasaan belajar, kondisi psikologis, dan aktivitas sosial
- Variabel target: Academic Performance

Dataset ini dipilih karena merepresentasikan kondisi mahasiswa secara holistik.



Exploratory Data Analysis (EDA)

Tahap EDA dilakukan untuk memahami struktur, distribusi, dan kualitas data.

Hasil EDA menunjukkan:

- Terdapat missing value pada atribut NumberOfFriend sebesar 4,04%
- Distribusi kelas pada variabel target tidak seimbang
- Tidak terdapat korelasi kuat antar variabel numerik

Temuan ini menjadi dasar dalam menentukan strategi preprocessing dan pemodelan.




Data Cleaning dan Preprocessing

Tahapan preprocessing yang dilakukan meliputi:

- Penanganan missing value menggunakan imputasi median
- Penanganan outlier menggunakan metode Interquartile Range (IQR)
- Transformasi data kategorikal dengan One-Hot Encoding
- Standarisasi data numerik menggunakan StandardScaler

Tahap ini bertujuan untuk meningkatkan kualitas data dan stabilitas model.



Metode Pemodelan

Penelitian ini menggunakan dua algoritma klasifikasi:

- Logistic Regression sebagai model baseline
- Random Forest sebagai model utama


Dataset dibagi menjadi data latih dan data uji dengan rasio 80:20. Random Forest dipilih karena kemampuannya dalam menangani data tabular dan mengurangi risiko overfitting melalui pendekatan ensemble.

Evaluasi Model

Evaluasi model dilakukan menggunakan metrik:

- Accuracy
- Precision
- Recall
- F1-Score


Karena dataset bersifat tidak seimbang, F1-Score digunakan sebagai metrik utama. Hasil evaluasi menunjukkan bahwa Random Forest memiliki performa yang lebih baik dibandingkan model baseline, khususnya pada metrik precision dan F1-score.



Confusion Matrix

Confusion Matrix digunakan untuk menganalisis distribusi hasil prediksi model secara lebih rinci. Model Random Forest mampu mengklasifikasikan kelas ekstrem dengan baik, namun masih mengalami kesalahan pada kelas menengah.

Hal ini menunjukkan adanya kemiripan pola data pada kategori performa akademik menengah.




Feature Importance

Hasil analisis feature importance menunjukkan bahwa:

- NumberOfFriend merupakan faktor paling berpengaruh
- Age dan SleepPerDayHours juga memberikan kontribusi signifikan

Temuan ini menegaskan bahwa faktor sosial dan gaya hidup memiliki peran penting dalam menentukan performa akademik mahasiswa.



Kesimpulan dan Keterbatasan

Kesimpulan penelitian ini menunjukkan bahwa algoritma Random Forest mampu memprediksi performa akademik mahasiswa dengan cukup baik dan stabil. Faktor non-akademik terbukti memiliki pengaruh yang lebih dominan dibandingkan faktor akademik teknis.

Keterbatasan penelitian ini terletak pada jumlah dataset yang relatif kecil. Penelitian selanjutnya disarankan untuk menggunakan data yang lebih besar serta melakukan optimasi parameter guna meningkatkan akurasi model.